

Apuntes_Pandas_2_Gestion_Ficheros_Tabulados

May 11, 2026

1 Apuntes Pandas 2: Lectura y conversion con ficheros tabulados

La libreria pandas incorpora modulos que permiten trabajar de manera sencilla con ficheros de texto con datos tabulados, aparte de otros tipos.

Los principales ficheros con los que vamos a trabajar son los **archivos .csv**, ya que son ficheros tabulados que **separan los datos con delimitadores**.

Para poder trabajar con los ficheros, necesitamos en primer lugar **acceder a ellos** convirtiendolos a lenguaje de Python y posteriormente **habra que volver a crear un fichero con su formato** para poder tener los datos fuera de Python.

Las siguientes funciones son para **el acceso a ficheros** y segun los delimitadores haremos uso de una u otra, como aparece en esta tabla:

Función	Descripción
<code>pd.read_csv()</code>	Carga datos de un fichero de tipo CSV, con los campos separados por comas ','
<code>pd.read_table()</code>	Carga datos de un fichero de texto tabular, con los campos separados por tabuladores ('\t')
<code>pd.read_fwf()</code>	Carga datos de un fichero de texto con columnas de ancho fijo

En las funciones *read_csv* y *read_table* podemos definir manualmente el caracter delimitador

```
[2]: import pandas as pd

dataset_vuelos = pd.read_csv("C:/proyecto-faust/M02_Python_Librerias_Big_Data/
↪UX_Material_Extra_Librerias/U10_datasets/NYC_flights_2013_MINI.csv" , sep =
↪";")
dataset_vuelos.shape
```

```
[2]: (33670, 20)
```

```
[4]: import pandas as pd
```

```
dataset_vuelos = pd.read_table("C:/proyecto-faust/M02_Python_Librerias_Big_Data/
↳UX_Material_Extra_Librerias/U10_datasets/NYC_flights_2013_MINI.csv" , sep =_
↳";")
dataset_vuelos.describe()
```

```
[4]:
```

	year	month	day	level_3	air_time \
count	33670.0	33670.000000	33670.000000	33670.000000	32738.000000
mean	2013.0	6.548946	15.709088	168404.486665	151.386676
std	0.0	3.414293	8.767922	97219.161380	93.899563
min	2013.0	1.000000	1.000000	3.000000	21.000000
25%	2013.0	4.000000	8.000000	84234.750000	83.000000
50%	2013.0	7.000000	16.000000	168430.500000	130.000000
75%	2013.0	10.000000	23.000000	252579.750000	192.000000
max	2013.0	12.000000	31.000000	336747.000000	683.000000

	arr_delay	arr_time	dep_delay	dep_time	distance \
count	32738.000000	32820.000000	32874.000000	32874.000000	33670.000000
mean	6.771611	1500.122273	12.632141	1348.109022	1047.661776
std	44.741969	535.595180	40.544789	489.644438	734.026342
min	-67.000000	1.000000	-23.000000	1.000000	17.000000
25%	-17.000000	1104.000000	-5.000000	907.000000	509.000000
50%	-5.000000	1534.000000	-2.000000	1359.000000	888.000000
75%	14.000000	1942.000000	11.000000	1747.000000	1389.000000
max	1272.000000	2400.000000	1301.000000	2400.000000	4983.000000

	flight	hour	minute	sched_arr_time	sched_dep_time
count	33670.000000	33670.000000	33670.000000	33670.000000	33670.000000
mean	1953.977933	13.178943	26.26044	1537.125601	1344.154707
std	1629.178382	4.673989	19.29607	498.285937	468.510580
min	1.000000	1.000000	0.00000	1.000000	106.000000
25%	543.000000	9.000000	8.00000	1125.000000	908.000000
50%	1473.000000	13.000000	29.00000	1556.000000	1359.000000
75%	3458.000000	17.000000	44.00000	1950.000000	1730.000000
max	6181.000000	23.000000	59.00000	2359.000000	2359.000000

Estas funciones permiten especificar distintos argumentos para poder visualizar específicamente ese contenido.

Estos argumentos son aquellos que se incluyen dentro de la expresión:

“nombre variable” = pd.read_csv/read_table (“ruta fichero” , “argumento1”, “argumento2”,...)

En la siguiente tabla aparecen algunos de los argumentos que se pueden definir principalmente:

Argumentos de <i>pd.read_csv()</i>	Descripción
filepath	Fichero a cargar. Puede ser una ruta de fichero local o una URL
sep	Carácter delimitador de campos. Por defecto <code>' '</code> para <i>read_csv</i> y <code>'\t'</code> para <i>read_table</i>
header	Indica si el fichero contiene una fila con los nombres de las columnas. Se puede indicar el número de la fila (empieza en cero). Por defecto, trata de inferir si hay nombres.
names	Lista opcional de nombres para las columnas
na_values	Lista de cadenas que representan valores ausentes (NAs) en el fichero
quotechar	Carácter utilizado en el fichero para entrecomillar cadenas de texto
encoding	Codificación o juego de caracteres utilizado en el fichero (p.ej. <i>ascii</i> , <i>latin1</i> , <i>utf8</i>)

```
[15]: import pandas as pd

dataset_vuelos = pd.read_table("C:/proyecto-faust/M02_Python_Librerias_Big_Data/
↳ UX_Material_Extra_Librerias/U10_datasets/NYC_flights_2013_MINI.csv" , sep =
↳ ";", na_values = "116")
print (" Indico que el valor 116 se reconozca como na_values y el resultado es:
↳ ")
print(40*" -")
print(dataset_vuelos.loc[0:10,["distance","origin"]])
```

Indico que el valor 116 se reconozca como na_values y el resultado es:

```
-----
      distance origin
0      1089.0     JFK
1      1576.0     JFK
2       764.0     LGA
3       187.0     JFK
4       738.0     LGA
5      1605.0     EWR
6      2475.0     JFK
7      2565.0     EWR
8      1069.0     JFK
9         NaN     EWR
10     944.0     JFK
```

Como mencionabamos antes, es necesario una vez se ha accedido a los ficheros, devolverlos a un **formato de salida fuera de python** en este caso .csv o tabulado.

Para ello utilizaremos `.to_csv()`

“nombre dataframe.to_csv(“nombre fichero“,”argumento 1“,”argumento 2“,...)

Es recomendable utilizar argumentos para exportar **los datos mas relevantes**, aqui aparece unba lista de argumentos utilizable:

Argumentos de df.to_csv()	Descripción
filepath	Fichero a cargar. Puede ser una ruta de fichero local o una URL
sep	Carácter delimitador de campos. Por defecto ','
header	Controla si se escriben los nombres de las columnas. Por defecto es True
columns	Lista opcional para seleccionar qué columnas escribir
na_rep	Carácter a escribir para los valores ausentes (NAs) en el fichero
index	Escribir el índice de filas (las etiquetas de filas)
index_label	Nombre a dar a la columna con las etiquetas de filas. Si False , no imprime nombre para la columna.
quotechar	Carácter para entrecomillar cadenas de texto
encoding	Codificación o juego de caracteres a utilizar en el fichero (p.ej. <i>ascii, latin1, utf8</i>)

```
[18]: import pandas as pd

dataset_vuelos = pd.read_table("C:/proyecto-faust/M02_Python_Librerias_Big_Data/
↳UX_Material_Extra_Librerias/U10_datasets/NYC_flights_2013_MINI.csv" , sep =
↳";", na_values = "116")
print (" Indico que el valor 116 se reconozca como na_values y el resultado es:
↳")
print(40*" -")
small_data = dataset_vuelos.loc[0:10,["distance","origin"]]
small_data.to_csv("C:/proyecto-faust/M02_Python_Librerias_Big_Data/
↳U2_Libreria_Pandas/prueba_exportacion_csv_dataset_small.csv", sep =";",
↳header =True, index =True, index_label = True)
```

Indico que el valor 116 se reconozca como na_values y el resultado es:
