

Apuntes_Pandas_06_Matplotlib

May 11, 2026

1 Matplotlib y Pandas: Caso practico

En esta unidad vamos a realizar una serie de ejercicios y explicaciones para conocer la libreria de Matplotlib y como esta se relaciona con pandas.

Matplotlib es una libreria dedicada a la visualizacion de datos, que da base a otras como Seaborn y StatsModels

Vamos a realizar todo el ejercicio utilizando un dataset especifico para ello.

Como hemos visto en el modulo de seaborn tendremos que activar matplotlib para que nos reconozca los titulos, aunque tambien lo importaremos.

```
[1]: %matplotlib inline
```

```
[3]: #1º cargamos el dataset y comprobamos que se visualiza correctamente
```

```
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt
```

```
Ruta = Path(r"C:\proyecto-faust\M02_Python_Librerias_Big_Data\U2_Libreria_Pandas\Ejercicios_clase_pandas\pe
↪csv")
df = pd.read_csv(Ruta)
print(df.head())
```

	studyName	Sample Number	Species	Region	\
0	PAL0708	1	Adelie Penguin (Pygoscelis adeliae)	Anvers	
1	PAL0708	2	Adelie Penguin (Pygoscelis adeliae)	Anvers	
2	PAL0708	3	Adelie Penguin (Pygoscelis adeliae)	Anvers	
3	PAL0708	4	Adelie Penguin (Pygoscelis adeliae)	Anvers	
4	PAL0708	5	Adelie Penguin (Pygoscelis adeliae)	Anvers	

	Island	Stage	Individual ID	Clutch Completion	Date Egg	\
0	Torgersen	Adult, 1 Egg Stage	N1A1	Yes	11/11/07	
1	Torgersen	Adult, 1 Egg Stage	N1A2	Yes	11/11/07	
2	Torgersen	Adult, 1 Egg Stage	N2A1	Yes	11/16/07	
3	Torgersen	Adult, 1 Egg Stage	N2A2	Yes	11/16/07	
4	Torgersen	Adult, 1 Egg Stage	N3A1	Yes	11/16/07	

	Culmen Length (mm)	Culmen Depth (mm)	Flipper Length (mm)	Body Mass (g)	\
0	39.1	18.7	181.0	3750.0	
1	39.5	17.4	186.0	3800.0	
2	40.3	18.0	195.0	3250.0	
3	NaN	NaN	NaN	NaN	
4	36.7	19.3	193.0	3450.0	

	Sex	Delta 15 N (o/oo)	Delta 13 C (o/oo)	\
0	MALE	NaN	NaN	
1	FEMALE	8.94956	-24.69454	
2	FEMALE	8.36821	-25.33302	
3	NaN	NaN	NaN	
4	FEMALE	8.76651	-25.32426	

	Comments
0	Not enough blood for isotopes.
1	NaN
2	NaN
3	Adult not sampled.
4	NaN

El dataset es un estudio de datos de características de pingüinos y para entender mejor sus variables, dado que son técnicas, veremos estas explicaciones aclaratorias:

- *Culmen*: Son las mediciones del pico del pingüino, midiéndose el largo y el ancho
- *Delta 15N/ Delta 13C*: Niveles de nitrógeno y Carbono
- *Clutch Completion*: Mide si se ha realizado toda la puesta de huevos o no
- *Flipper*: Es la aleta

El conjunto de datos tiene una estructura de *long-form data* por lo que cada línea de la estructura corresponde a una observación

1.1 1º Enunciado: Visualización básica de los datos

Hay una serie de pautas que tenemos que saber hacer siempre que trabajemos con datos y cumplamos estas peticiones

Debemos comprender que datos tenemos, si hay NaN's, ver ejemplos de representación.... info básica pero necesaria

- Cargar el dataset
- Mostrar los nombres de las columnas
- Mostrar las 5 primeras filas
- Mostrar el total de filas y columnas
- Mostrar información general del dataset

```
[10]: #1º cargamos el dataset
from pathlib import Path
import pandas as pd
```

```

import matplotlib.pyplot as plt

Ruta = Path(r"C:\proyecto-faust\M02_Python_Librerias_Big_Data\U2_Libreria_Pandas\Ejercicios_clase_pandas\pe
↪csv")
df = pd.read_csv(Ruta)

#2º Mostramos el nombre de las columnas - mediante .columns
print(df.columns)
print(100*"_")

#3º Mostramos las 5 primeras filas - mediante .head()
print(df.head())
print( 100*"_")

#4º Mostramos el total de las filasy columnas - mediante .shape
print(df.shape)
print( 100*"_")

#5º Mostramos info general del dataset - mediante .info()
df.info()

```

```

Index(['studyName', 'Sample Number', 'Species', 'Region', 'Island', 'Stage',
      'Individual ID', 'Clutch Completion', 'Date Egg', 'Culmen Length (mm)',
      'Culmen Depth (mm)', 'Flipper Length (mm)', 'Body Mass (g)', 'Sex',
      'Delta 15 N (o/oo)', 'Delta 13 C (o/oo)', 'Comments'],
      dtype='object')

```

```

-----
studyName  Sample Number      Species  Region \
0  PAL0708           1  Adelie Penguin (Pygoscelis adeliae)  Anvers
1  PAL0708           2  Adelie Penguin (Pygoscelis adeliae)  Anvers
2  PAL0708           3  Adelie Penguin (Pygoscelis adeliae)  Anvers
3  PAL0708           4  Adelie Penguin (Pygoscelis adeliae)  Anvers
4  PAL0708           5  Adelie Penguin (Pygoscelis adeliae)  Anvers

```

```

      Island      Stage Individual ID Clutch Completion  Date Egg \
0  Torgersen  Adult, 1 Egg Stage      N1A1           Yes  11/11/07
1  Torgersen  Adult, 1 Egg Stage      N1A2           Yes  11/11/07
2  Torgersen  Adult, 1 Egg Stage      N2A1           Yes  11/16/07
3  Torgersen  Adult, 1 Egg Stage      N2A2           Yes  11/16/07
4  Torgersen  Adult, 1 Egg Stage      N3A1           Yes  11/16/07

```

```

      Culmen Length (mm)  Culmen Depth (mm)  Flipper Length (mm)  Body Mass (g) \
0           39.1           18.7           181.0           3750.0
1           39.5           17.4           186.0           3800.0
2           40.3           18.0           195.0           3250.0
3           NaN           NaN           NaN           NaN

```

4	36.7	19.3	193.0	3450.0
---	------	------	-------	--------

	Sex	Delta 15 N (o/oo)	Delta 13 C (o/oo)	\
0	MALE	NaN	NaN	
1	FEMALE	8.94956	-24.69454	
2	FEMALE	8.36821	-25.33302	
3	NaN	NaN	NaN	
4	FEMALE	8.76651	-25.32426	

	Comments
0	Not enough blood for isotopes.
1	NaN
2	NaN
3	Adult not sampled.
4	NaN

(344, 17)

```
<class 'pandas.core.frame.DataFrame'>
```

RangeIndex: 344 entries, 0 to 343

Data columns (total 17 columns):

#	Column	Non-Null Count	Dtype
0	studyName	344 non-null	object
1	Sample Number	344 non-null	int64
2	Species	344 non-null	object
3	Region	344 non-null	object
4	Island	344 non-null	object
5	Stage	344 non-null	object
6	Individual ID	344 non-null	object
7	Clutch Completion	344 non-null	object
8	Date Egg	344 non-null	object
9	Culmen Length (mm)	342 non-null	float64
10	Culmen Depth (mm)	342 non-null	float64
11	Flipper Length (mm)	342 non-null	float64
12	Body Mass (g)	342 non-null	float64
13	Sex	333 non-null	object
14	Delta 15 N (o/oo)	330 non-null	float64
15	Delta 13 C (o/oo)	331 non-null	float64
16	Comments	26 non-null	object

dtypes: float64(6), int64(1), object(10)

memory usage: 45.8+ KB

1.2 2º Enunciado: Gestion de NaNs del dataset

Otro aspecto inicial a realizar antes de ponernos a trabajar con los datos, es gestionar los NaN del dataset.

Trabajar primero estos valores no reconocidos, mejorara nuestra capacidad de tratamiento y calculo de todo el dataset, para evitar errores

- Comprueba el numero de NaN por columna
- Eliminar las columnas *Delta 15N/ Delta 13C*
- Completar la columna *Comments* con *No Comments* si hay NaN
- Para las columnas de medidas del piso, aleta y peso, rellenar los NaN con medias del total
- Para la columna *Sex* transformar el tipo a *category* y utilizar el valor que mas se repita de *Male/Female* para rellenar los NaN
- Volver a comprobar los NaN por columna

```
[17]: #1º cargamos el dataset
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt

Ruta = Path(r"C:\
    \proyecto-faust\M02_Python_Librerias_Big_Data\U2_Libreria_Pandas\Ejercicios_clase_pandas\pe
    \csv")
df = pd.read_csv(Ruta)

#2º Comprobamos los NaN - utilizaremos .isnull() que indica valores nulos por
    \variable y adicionalmente utilizaremos .sum() para recopilarlos en 1 valor.
print(df.isnull().sum())
print( 40*"_")

#3º Eliminamos las columnas - utilizamos .drop() para cada columna. Indicaremos
    \nombre de la variable y su eje columna.
df = df.drop("Delta 15 N (o/oo)", axis = "columns").drop("Delta 13 C (o/oo)",
    \axis = "columns")

#4º Completamos comments - seleccionamos la columna y modificamos su valor
    \seleccionando la columna + .fillna( con lo que queramos completar)
df["Comments"] = df["Comments"].fillna("No Comments")

#5º Rellenamos la media de las medidas - seleccionamos la columna y modificamos
    \su valor seleccionando la columna + .fillna( columna. mean())
df["Culmen Length (mm)"] = df["Culmen Length (mm)"].fillna(df["Culmen Length
    \ (mm)"].mean())
df["Culmen Depth (mm)"] = df["Culmen Depth (mm)"].fillna(df["Culmen Depth
    \ (mm)"].mean())
df["Flipper Length (mm)"] = df["Flipper Length (mm)"].fillna(df["Flipper Length
    \ (mm)"].mean())
```

```

df["Body Mass (g)"] = df["Body Mass (g)"].fillna(df["Body Mass (g)"].mean())

#6º - 1/2 Cambiamos categoria para sex - seleccionamos la columnas y cambiamos
↳ el tipo con .astype("category")
df["Sex"] = df["Sex"].astype("category")

#6º - 2/2 Completamos datos con el valor que mas se repita.
# Crearemos una variable con los valores mas repetidos mediante .
↳ describe()["top"]
# .describe() en una variable , nos sacara varios datos y uno de ellos
↳ es "top", como el mas repetido.
# luego incluirlos a la columna mediante .fillna(variable)
sex = df["Sex"].describe()["top"]
df["Sex"] = df["Sex"].fillna(sex)

#7º Volvemos a comprobar los NaN
print(df.isnull().sum())

```

```

studyName      0
Sample Number  0
Species        0
Region         0
Island         0
Stage          0
Individual ID  0
Clutch Completion  0
Date Egg       0
Culmen Length (mm)  2
Culmen Depth (mm)  2
Flipper Length (mm)  2
Body Mass (g)   2
Sex            11
Delta 15 N (o/oo)  14
Delta 13 C (o/oo)  13
Comments       318
dtype: int64

```

```

-----
studyName      0
Sample Number  0
Species        0
Region         0
Island         0
Stage          0
Individual ID  0
Clutch Completion  0
Date Egg       0
Culmen Length (mm)  0

```

```

Culmen Depth (mm)      0
Flipper Length (mm)    0
Body Mass (g)          0
Sex                    0
Comments               0
dtype: int64

```

1.3 3º Enunciado: Calculos basicos

Una vez el dataset esta listo, podemos realizar algun calculo basico sobre el mismo, como las medias, porcentajes, recuentos, max o min,...

En este y mas ejercicios, dado que hemos generado un dataframe limpio de NaN, podremos o bien, cargar el script anterior generado o guardarlo en uno nuevo para poder realizar calculos sobre este.

Esta 2º opcion no se recomienda salvo que tenga sentido guardar el dataframe ya que podemos generar muchos archivos *basura* en nuestro proceso de gestion de datos.

- Media de ancho y largura del pico, peso y tamalio de la aleta por especie > **Siempre que nos pidan extraer un dato o datos *por una variable* hay que utilizar .groupby()**
- % de “clutch completion” de una especie en concreto: Chinstrap penguin (*Pygoscelis antarctica*)
- nº de especies por isla y guardarlos en un nuevo dataframe

```

[25]: #1º cargamos el dataset y modificaciones hechas anteriormente
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt

Ruta = Path(r"C:\
    ↪\proyecto-faust\M02_Python_Librerias_Big_Data\U2_Libreria_Pandas\Ejercicios_clase_pandas\pe
    ↪csv")
df = pd.read_csv(Ruta)
df = df.drop("Delta 15 N (o/oo)", axis = "columns").drop("Delta 13 C (o/oo)",
    ↪axis = "columns")
df["Comments"] = df["Comments"].fillna("No Comments")
df["Culmen Length (mm)"] = df["Culmen Length (mm)"].fillna(df["Culmen Length_
    ↪(mm)"].mean())
df["Culmen Depth (mm)"] = df["Culmen Depth (mm)"].fillna(df["Culmen Depth_
    ↪(mm)"].mean())
df["Flipper Length (mm)"] = df["Flipper Length (mm)"].fillna(df["Flipper Length_
    ↪(mm)"].mean())
df["Body Mass (g)"] = df["Body Mass (g)"].fillna(df["Body Mass (g)"].mean())
df["Sex"] = df["Sex"].astype("category")
sex = df["Sex"].describe()["top"]
df["Sex"] = df["Sex"].fillna(sex)

```

```

#2º Agrupamos por especie a traves de .groupby("Species") y calculamos las
↳medias de las columnas [[:]].mean()

medias = df.groupby("Species")[["Culmen Length (mm)", "Culmen Depth (mm)",
↳"Flipper Length (mm)", "Body Mass (g)"]].mean()
print(medias)
print(40*"_")

#3º 1/3 - Cambiamos la variable a category mediante .astype("category")

df["Clutch Completion"] = df["Clutch Completion"].astype("category")

#3º 2/3 - El proceso es:
    #0º Generamos una variable para contabilizar la frecuencia y otra la
↳cantidad, para posteriormente hacer el calculo de %.
    #1º utilizamos una mascara booleana para filtrar esa especie
    #2º agrupamos los datos para tener 1 unica observacion
    #3º seleccionamos la columna de clutch completion y Utilizamos .
↳describe()[...] para elegir en una la frecuencia y en otra la cantidad.
cc_freq = df[df["Species"] == "Chinstrap penguin (Pygoscelis antarctica)"].
↳groupby("Species")["Clutch Completion"].describe()["freq"]
cc_count = df[df["Species"] == "Chinstrap penguin (Pygoscelis antarctica)"].
↳groupby("Species")["Clutch Completion"].describe()["count"]

# 3º 3/3 - Calculamos el % dividiendo la frecuencia / el total *100

print((cc_freq / cc_count)*100)
print(40*"_")

#4º Generamos un dataframe con pd.DataFrame de lo que extraemos por un .
↳groupby( ["Species", "Island"]) y calculamos el conteo de islas en otra
↳columna.
    # Cambiamos el nombre de la columna del conteo de "Island" a "Count"

df_island = pd.DataFrame(df.groupby(["Island", "Species"])["Island"].count()).
↳rename(columns ={"Island": "Count"})
print(df_island)

```

Species	Culmen Length (mm) \
Adelie Penguin (Pygoscelis adeliae)	38.825144
Chinstrap penguin (Pygoscelis antarctica)	48.833824
Gentoo penguin (Pygoscelis papua)	47.475983

Species	Culmen Depth (mm) \
---------	---------------------

Adelie Penguin (Pygoscelis adeliae)	18.338495
Chinstrap penguin (Pygoscelis antarctica)	18.420588
Gentoo penguin (Pygoscelis papua)	14.999606

Species	Flipper Length (mm)	Body Mass (g)
Adelie Penguin (Pygoscelis adeliae)	190.025758	3703.958910
Chinstrap penguin (Pygoscelis antarctica)	195.823529	3733.088235
Gentoo penguin (Pygoscelis papua)	217.055768	5068.965761

```
-----
Species
Chinstrap penguin (Pygoscelis antarctica)    79.411765
dtype: object
-----
```

Island	Species	Count
Biscoe	Adelie Penguin (Pygoscelis adeliae)	44
	Gentoo penguin (Pygoscelis papua)	124
Dream	Adelie Penguin (Pygoscelis adeliae)	56
	Chinstrap penguin (Pygoscelis antarctica)	68
Torgersen	Adelie Penguin (Pygoscelis adeliae)	52

1.4 4º Enunciado: Visualizacion de datos con Matplotlib

Finalmente llegamos al final del ejercicio y core de la actividad, como es la visualizacion de datos con *matplotlib*

Sin las partes previas, seria imposible realizar este ultimo ejercicio, ya que el core de la visualizacion, es la manipulacion y tratamiento de los datos

- A partir del Dataframe creado anterior, realizar un grafico de barras verticales con el nº de ejemplares de cada especie/isla. Ademas gira la leyenda a la derecha y aumenta el tamaño de letra. > **Si tenemos los datos muy trabajados y organizados a la hora de visualizarlos, puedes utilizar la funcion *plot*. “nombre del grafico” para hacerlo mas rapido**
- Crearemos un grafico de dispersion (*scatter*) relacionando el tamaño de la aleta con la masa del cuerpo. Ejes: x = Flipper Length (mm) / y = Body Mass (g)
- Crear grafico de lineas para el peso por especie y sexo. Rotar la leyenda a la derecha, cambia el tamaño de letra y pon estos nombres de ejes: x = “Specie-Sex” / y = “Body Mass (g)”

```
[11]: #1º cargamos el dataset y modificaciones hechas anteriormente, que nos valgan
      ↪ para el ejercicio.
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt

Ruta = Path(r"C:
      ↪ \proyecto-faust\M02_Python_Librerias_Big_Data\U2_Libreria_Pandas\Ejercicios_clase_pandas\pe
      ↪ csv")
```

```

df = pd.read_csv(Ruta)

df = df.drop("Delta 15 N (o/oo)", axis = "columns").drop("Delta 13 C (o/oo)",
    ↪axis = "columns")

df["Comments"] = df["Comments"].fillna("No Comments")
df["Culmen Length (mm)"] = df["Culmen Length (mm)"].fillna(df["Culmen Length_
    ↪(mm)"].mean())
df["Culmen Depth (mm)"] = df["Culmen Depth (mm)"].fillna(df["Culmen Depth_
    ↪(mm)"].mean())
df["Flipper Length (mm)"] = df["Flipper Length (mm)"].fillna(df["Flipper Length_
    ↪(mm)"].mean())
df["Body Mass (g)"] = df["Body Mass (g)"].fillna(df["Body Mass (g)"].mean())

df["Sex"] = df["Sex"].astype("category")
sex = df["Sex"].describe()["top"]
df["Sex"] = df["Sex"].fillna(sex)

df["Clutch Completion"] = df["Clutch Completion"].astype("category")
df_island = pd.DataFrame(df.groupby(["Island", "Species"])["Island"].count()).
    ↪rename(columns = {"Island": "Count"})

#2º Generamos un grafico de barras en base al dataframe "df_island" con .plot.
    ↪bar() y cambiaremos la leyenda con plt.xticks
# Utilizaremos los parametros " rotation = ", " ha = " para cambiar la
    ↪direccion y "fontsize = " para el tamaño de fuente
# Nos saltamos el uso de matplotlib y su configuracion de graficos en este
    ↪ejemplo.

df_island.plot.bar()
plt.xticks (rotation = 30, ha = "right", fontsize = 10)

#3º Generamos un grafico de dispersion siguiendo estos pasos
    #1º Generamos una figura nueva mediante figure.plt()
    #2º mediante plt.scatter() eligiendo Ejes: x = Flipper Length (mm) / y =
    ↪Body Mass (g)
    #3º Incluimos titulos a los ejes mediante xlabel / ylabel

fig_1 = plt.figure()
plt.scatter(x = df["Flipper Length (mm)"], y = df["Body Mass (g)"], color =
    ↪"green")
plt.xlabel("Flipper Length (mm)")
plt.ylabel("Body Mass (g)")

#4º Generaremos un grafico de lineas siguiendo estos pasos:

```

#1º Haremos el filtrado, creando un dataframe, luego una agrupacion
 ↳ mediante `.groupby(["Species", "Sex"])` y calculamos la media del peso `["Body Mass (g)"].mean()`
 #2º Generamos un grafico de lineas mediante `.plot(kind="line")`
 #3º Rotamos los titulos y el tamaño con `.xticks(rotation=, ha=, fontsize=`
 ↳ `)` y los nombres de los titulos con `xlabel, ylabel`.

```
df_2 = pd.DataFrame(df.groupby(["Species", "Sex"])["Body Mass (g)"].mean())
df_2.plot(kind="line")
plt.xticks(rotation=45, ha="left", fontsize=6)
plt.xlabel("Specie-Sex")
plt.ylabel("Body Mass (g)")
```

C:\Users\insau\AppData\Local\Temp\ipykernel_5100\248254479.py:46: FutureWarning:
 The default of observed=False is deprecated and will be changed to True in a
 future version of pandas. Pass observed=False to retain current behavior or
 observed=True to adopt the future default and silence this warning.

```
df_2 = pd.DataFrame(df.groupby(["Species", "Sex"])["Body Mass (g)"].mean())
```

```
[11]: Text(0, 0.5, 'Body Mass (g)')
```





