

00_Apuntes_Scikit-Learn_Machine_Learning

May 11, 2026

1 Apuntes: libreria Scikit-Learn en python para Machine Learning

En este cuaderno vamos a explorar la libreria Scikit-Learn que esta diseñada para realizar modelos de prediccion y clasificacion de Machine Learning, mediante arboles de decision.

Repasemos un poco el mundo del machine learning antes de dar paso a la libreria

1.1 1. Machine Learning: Conceptos e ideas de la tecnologia a recordar

Esta libreria esta centrada en realizar algoritmos de Machine Learning, siendo esta, **el area de la inteligencia artificial encargada de replicar el comportamiento a partir de datos**

1.1.1 Sus usos mas habituales son:

- Aprendizaje automatico sin interaccion humana
- Uso de algoritmos para realizar clasificaciones y/o predicciones.

1.1.2 Para el machine learning necesitamos:

- Datos
- Un patron que no podamos identificar matematicamente (o desconozcamos como identificarlo)


1.1.3 Proceso de Machine Learning: Conceptos basicos

La relacion de los conceptos de manera simplificada, es la siguiente:

- Con los datos organizados, **escogemos *features* que permiten generar algoritmos** (las hipotesis de prediccion)
- Estos algoritmos son **entrenados con un conjunto de datos para generar un modelo predictivo**
- **El modelo es puesto a prueba con otros datos de testeo y posteriormente evaluado**
- Una vez confirmado el modelo, **las etiquetas son los datos clasificados**

- **Modelo:** representación matemática de un proceso del mundo real. Para generar este modelo debemos proporcionar datos de entrenamiento y un algoritmo del que aprender.
- **Algoritmo:** es la hipótesis de partida antes de realizar el entrenamiento con los datos reales. Existen muchos algoritmos:
 - Regresión lineal, árbol de decisión, SVM (Support Vector Machines), Naive Bayes...
- **Training/Learning:** proceso de aplicación de un algoritmo a datos de entrenamiento. El algoritmo de entrenamiento encuentra patrones. La salida del entrenamiento es el modelo que podemos utilizar para hacer predicciones.
- **Feature:** variables independientes que sirven como entrada. Cada característica (atributo) de un dato es una *feature*.
- **Etiqueta:** salida final. Datos que ya se han clasificado.

Aquí podemos ver el diagrama de lo anteriormente explicado:



1.1.4 Tipos de Algoritmos en Machine Learning

Existen 3 tipos concretos, explicados a continuación:


- **Clasificación:** proceso por el que se categorizan los datos en clases predefinidas (es “spam” o “no spam”)
- **Clustering:** proceso por el que se agrupan los datos. Los grupos se crean a partir de características (*features*) similares.
- **Regresión:** proceso de predicción con valores continuos. Permite identificar la distribución de tendencias basados en los datos. Por ejemplo, calcular el sueldo de una persona según edad y educación.

1.1.5 Tipos de Aprendizaje de Machine Learning

Existen 3 tipos de entrenamientos, simplificados:

- **Aprendizajes No Supervisados:** Se utilizan para algoritmos de **Clustering**, ya que los resultados obtenidos finales vendrán dados por patrones no identificables a simple vista
 - **Aprendizajes Supervisados:** Se utiliza para algoritmos de **regresión y clasificación**, ya que requiere que un humano le de la respuesta final para que vaya aprendiendo y pueda realizarlo de manera autónoma.
 - **Aprendizajes Reforzados:** Un algoritmo que explora datos nuevos, realiza un proceso mediante prueba y error, hasta obtener el resultado final.
-
- **Supervised:** algoritmos que crean un modelo a partir de datos de entrada con los datos de salida deseados.
 - **Unsupervised:** algoritmos que solamente reciben datos de entrada (no hay salida deseada) y donde se intenta agrupar / clusterizar los datos.
 - **Reinforcement:** algoritmos que toman acción sobre el entorno. Trabaja sobre exploración (sobre datos no trabajados) y entornos posiblemente complejos con prueba y error hasta encontrar una solución.

Algunos ejemplos de uso de cada tipo de aprendizaje son los que aparecen en el siguiente gráfico:



1.2 2. Scikit - Learn: Libreria en python para Machine Learning

Es una libreria dedicada al desarrollo de modelos de machine learning, se caracteriza:

- Facilita de manera simple **acceso a algoritmos de los distintos tipos** (supervisados y no supervisados)
- Incluye todas las herramientas para procesar datos o gestionar modelos

Se instala a traves de ***pip install scikit-learn***

1.2.1 Conceptos de la libreria a conocer

Hay varios elementos a conocer pertenecientes a esta libreria:

- ***Estimators*** (o estimadores): Es la representacion de un algoritmo con un modelo entrenado.
> Dispondremos del algoritmo de machine learning y el modelo que podremos ajustar con los datos de entrenamiento
- ***Samples Matrix*** (o matriz de muestra): Son los datos de muestra para entrenar el modelo que se representan como matriz. Filas so registros y columnas atributos (***features***).

1.2.2 Metodos propios de la libreria

Existen 2 funciones propias de la libreria que ayudan a capacitar los modelos:

- ***.fit()***(funcion de ajuste): Es un metodo para ajustar y entrenar con datos el algoritmo + modelo de machine learning. > Casi siempre **se reciben 2 argumentos en esta funcion** (son arrays)(Hablamos de algoritmos supervisados porque requieren de intervencion humana):

> > > Matriz de muestra: conjunto de datos de muestra con todas las características > > >
 > Valores objetivo: Seran los datos objetivo. > > > > **Si es un modelo de clasificacion = seran numeros enteros o fijos** > > > > **Si es un modelo de regresion = seran numero reales para estimar la distribucion de los datos***

- **.predict()**(funcion de prediccion): Metodo para predecir los datos utilizando el modelo y algoritmos (estimador) entrenado

```
[2]: pip install scikit-learn
```

```
Requirement already satisfied: scikit-learn in
c:\users\insau\anaconda3\lib\site-packages (1.6.1)
Requirement already satisfied: numpy>=1.19.5 in
c:\users\insau\anaconda3\lib\site-packages (from scikit-learn) (2.1.3)
Requirement already satisfied: scipy>=1.6.0 in
c:\users\insau\anaconda3\lib\site-packages (from scikit-learn) (1.15.3)
Requirement already satisfied: joblib>=1.2.0 in
c:\users\insau\anaconda3\lib\site-packages (from scikit-learn) (1.4.2)
Requirement already satisfied: threadpoolctl>=3.1.0 in
c:\users\insau\anaconda3\lib\site-packages (from scikit-learn) (3.5.0)
Note: you may need to restart the kernel to use updated packages.
```

1.3 Ejemplo de uso de libreria Scikit-Learn

```
[1]: # 1. Importamos de la libreria un algoritmo
      # RandomForestClassifier es un algoritmo de clasificacion y de tipo arbol
      ↪ de decision

      from sklearn.ensemble import RandomForestClassifier
```

```
[7]: # 2. Generamos un estimador y los datos para entrenar el algoritmo.
      # Generamos 2 variables con numpy arrays.
      # Se cumple estas reglas:
      # 1º Siempre deberemos darles los datos de muestra y los datos de
      ↪ clasificacion
      # 2º Debera haber tantos datos de clasificacion como datos de muestra
      ↪ (hay 2 arrays de muestra = 2 valores objetivo)

      clf = RandomForestClassifier(random_state=0)
      x = [[6, 45, 79], [7, 68, 97]] # Estos seran la matriz de muestra
      y = [0,1] # Estos seran los valores objetivos
```

```
[8]: # 3. Ajustamos el modelo con .fit() y los datos

      clf.fit(x,y)
```

```
[8]: RandomForestClassifier(random_state=0)
```

```
[9]: # 4. Generamos la prediccion con .predict()  
      # la prediccion solo recibe un parametro  
  
      clf.predict(x)
```

```
[9]: array([0, 1])
```