



Σavante

**Trabajo Final:
Herramientas BigData**



INSTRUCCIONES

Introducción del examen

Para la realización de este trabajo final será necesario que apliques los conocimientos que has adquirido a lo largo de las unidades que componen la asignatura "Herramientas BigData". Además, también vas a tener que realizar algo de investigación y aprender a utilizar una plataforma real en la nube para resolver el ejercicio.

En este trabajo deberás mostrar no solo los conocimientos que has aprendido, si no también tu capacidad para trabajar con estas tecnologías.

Archivos adjuntos

Para completar este ejercicio tendrás que hacer uso de los ficheros adjuntos:

- **Un archivo comprimido llamado: "EjercicioFinal_BigData_FicherosDatos.zip"**
- **Un archivo .ipynb llamado: HerramientasBigData_CuadernoEnunciado.ipynb.ipynb**

En el archivo comprimido encontrarás los ficheros con los datos que deberás utilizar para resolver el trabajo. Una vez descargues el archivo deberás descomprimirlo. El archivo constará de tres ficheros:

- **precio_md.csv** _ Donde se encontrarán los datos con los precios horarios de la electricidad
- **preveol.csv** _ Donde se encontrarán datos de generación eólica prevista para cada hora
- **prvdem.csv** _ Donde se encontrarán datos de la demanda prevista para cada hora

Si te interesa podrás ver el contenido de cada uno de los archivos abriéndolos desde un editor de texto plano (bloc de notas) o desde un programa de hojas de cálculo (como Excel). Esto te permitirá familiarizarte con los datos antes de comenzar a utilizarlos, pero **¡recuerda no sobrescribir el contenido de los ficheros!**

Por otro lado, el archivo **.ipynb** adjunto es un cuaderno de trabajo que deberás cargar en **Google Colab** siguiendo las instrucciones que te facilitaremos más adelante. El cuaderno contiene una serie de tareas de programación con **Spark** y **Pandas** que deberás completar en el propio cuaderno. Cuando lo hayas completado, tendrás que exportarlo y enviarlo como resolución del ejercicio.

En el propio cuaderno se incluirán las indicaciones que deberás seguir para completar cada uno de los apartados evaluables. Si necesitas alguna aclaración adicional recuerda consultar con los profesores a través de la mensajería del campus.



Entrega del proyecto

Para que la entrega del trabajo se considere válida será necesario que nos envíes una carpeta comprimida en zip o rar, que contenga:

- El cuaderno de trabajo, tras haber completado cada una de las celdas de código solicitadas, en formato .ipynb.

Para poder descargar el archivo una vez finalizado en formato .ipynb será necesario que hagas clic en la opción del menú "File" y elijas la opción llamada "Download" lo que te permitirá elegir la descargar el cuaderno en el estado actual en formato .ipynb

- El cuaderno de trabajo finalizado exportado como un archivo .PDF.

Para poder descargar el archivo en formato PDF, será necesario que hagas clic en la opción del menú llamada "File", tras ello, deberás elegir la opción llamada "Imprimir" y como opción destino será necesario que elijas "Guardar como PDF".

El cuaderno de trabajo que debes enviarnos, en ambos formatos (.ipynb y .pdf) deberá llamarse: "TFHerramientasBigData_NombreApellidos.extension".

RECOMENDACIONES:

- Revisa lo que se solicita en cada una de las celdas del trabajo antes de comenzar a realizarlo.
- Consulta todas las dudas que te hayan surgido tras leer el enunciado del ejercicio con los docentes del curso para que puedan ayudarte a resolverlas, antes de que comiences su desarrollo.

IMPORTANTE:

- Para que el trabajo se pueda valorar será necesario que se hayan completado todos sus apartados.
- Si el trabajo NO se entrega siguiendo las instrucciones especificadas en este enunciado, quedará suspendido automáticamente.



DESARROLLO DEL EJERCICIO

Como se ha mencionado anteriormente para realizar el trabajo será necesario que hagas uso de una plataforma en la nube llamada **Google Colab**.

Google Colab es una plataforma basada en la nube donde los usuarios podrán escribir y ejecutar código utilizando el lenguaje de Python, para áreas como análisis de datos y aprendizaje automático. Es una herramienta muy popular debido a su facilidad de uso y accesibilidad, ya que no requiere instalación y se puede utilizar directamente desde el navegador. Además, ofrece integración con otros servicios de Google como Google Drive, así como la posibilidad de colaborar con otros usuarios.

Dentro de la plataforma podrás cargar ficheros de datos de forma temporal o importarlos desde Google Drive, así como importar o crear cuadernos de trabajo interactivos (**archivos .ipynb**) donde podrás analizar datos utilizando **Spark** e incluso compartir tu trabajo fácilmente con otros programadores, entre muchas otras opciones.

1.1 _ Acceso a Google Colab

Google Colab es una plataforma inicialmente gratuita que está disponible para todos los usuarios que dispongan de una cuenta de Google. Incluye opciones de pago adicionales (como servicios de suscripción o de pago por uso) en caso de que se necesite contratar recursos avanzados o una mayor cantidad de estos.

De forma gratuita, la plataforma incluye todas las herramientas necesarias para trabajar con Spark en la nube, por lo que para la realización de este trabajo no será necesario adquirir ningún servicio de pago o suscripción.

El primer paso para utilizar **Google Colab** será acceder a su página oficial, algo que podrás realizar desde el siguiente enlace:

<https://colab.research.google.com>

Una vez dentro, encontrarás una pantalla de bienvenida a la aplicación. Para comenzar a utilizarla será necesario que hagas clic en el botón llamado **Iniciar sesión** situado en la parte superior derecha, lo que te permitirá:

- Iniciar sesión en tu cuenta de Google.
- Crear una cuenta de Google en caso de que no tuvieses ninguna.



Trabajo final: Herramientas BigData




Imagen que muestra la pantalla de bienvenida a Google Colab así como el botón "Iniciar sesión" situado en la parte superior derecha




1.2 _ Google Colab: Cómo subir los archivos .csv

Para poder realizar el ejercicio será necesario hacer uso de los archivos .csv que habías descargado desde el campus y para ello, utilizaremos la integración que tiene Google Colab con Google Drive.

Este paso solo lo tendrás que hacer una vez, ya que una vez subas los archivos a tu Drive de Google se mantendrán allí hasta que decidas eliminarlos.

En primer lugar, será necesario que accedas a Google Drive con la misma cuenta que utilizaste para acceder a **Google Colab**, tras ello deberás crear una carpeta, por ejemplo, con el nombre **bigdata_csv** y allí, deberás subir los tres archivos **.csv**



Una vez subidos a Google Drive podrás utilizarlos desde el cuaderno en Google Colab.



1.3 _ Google Colab: Cómo importar el cuaderno .ipynb

Independientemente de si has elegido una cuenta de Google ya existente o si has creado una nueva para utilizar la aplicación, te aparecerá una ventana emergente llamada "**Abrir cuaderno**" dentro de la pantalla de **Google Colab**, donde podrás elegir:

- Ver el documento de bienvenida a la plataforma
- Acceder a ejemplos de cuadernos
- Crear un nuevo cuaderno
- Acceder a un archivo existente en tu cuenta de Google Drive
- Subir un cuaderno a la plataforma

En ella deberás elegir la opción "Subir" del menú lateral y después arrastrar el cuaderno que habías descargado, llamado **Big Data en la Nube – Cuaderno Enunciado.ipynb** para cargarlo. También es posible, elegir la opción "Explorar" si prefieres seleccionar el archivo desde una ubicación determinada de tu ordenador a través del "Explorador de archivos" disponible en tu equipo.




Imagen que muestra la ventana emergente que te permitirá subir tu cuaderno a Google Colab



Trabajo final: Herramientas BigData

Una vez elegido el archivo, este se cargará automáticamente y ya podrás comenzar a trabajar en él.

The screenshot shows the Google Colab interface with a Jupyter Notebook titled "Ejercicio Final - Big Data en la Nube". The notebook is open to the "Índice" section, which lists various tasks and sub-tasks. The main content area shows the "Instrucciones del examen" section, detailing the requirements for the final exam.

Ejercicio Final - Big Data en la Nube

- Instrucciones del examen

Para la realización de este examen será necesario que completes seis tareas:

- Tarea 1 _ Acceso a los archivos .csv y revisión del contenido
- Tarea 2 _ Visualización gráfica a través de Pandas y Seaborn
- Tarea 3 _ Visualización gráfica con Spark
- Tarea 4 _ Relación entre variables
- Tarea 5 _ Modelos estadísticos
- Tarea 6 _ Entrenamiento del modelo con datos recientes

Cada una de las tareas se compondrá de varios apartados. Es importante tener en cuenta que las tareas presentan una dependencia entre sí, por lo que si las primeras no se realizan correctamente automáticamente el resto estarán mal de forma automática.

A lo largo del cuaderno, encontrarás indicaciones que te ayudarán a comprender qué debes realizar en cada tarea de forma general y en cada uno de sus apartados de forma específica. Por lo que deberás completar las celdas de código situadas debajo de las celdas de texto que contendrán los enunciados, siguiendo las instrucciones que se te han proporcionado en ellos.

En ocasiones, es posible que se presenten funcionalidades que no se han visto durante el curso, para que tengáis que investigar su uso, pero no te preocupes ya que serán sencillas.

Presta especial atención a cómo se te pide resolver cada apartado. En algunos casos se te pedirá que uses PySpark. En otros casos se te pedirá que uses Pandas. Utiliza siempre la tecnología que se solicite para evitar penalizaciones en la nota final del trabajo.

- Comentarios y sugerencias

A lo largo del trabajo podrás ir probando el código que estás desarrollando, no dudes en probarlo tantas veces como necesites.

Imagen que muestra el cuaderno de trabajo ya cargado en Google Colab.