



Σavante

CIENCIA DE DATOS: EXAMEN FINAL



INSTRUCCIONES

Realización del trabajo

Para la realización de este trabajo final deberás elaborar un archivo .Rmd dónde resolverás cada uno de los ejercicios propuestos en este enunciado.

Entrega del trabajo

Para que la entrega se considere válida será necesario que nos envíes una carpeta comprimida que contenga:

- El archivo .csv dónde se encuentran los datos que utilizarás para la realización de los ejercicios y que se adjunta en la sección del trabajo final.
- El archivo .Rmd dónde habrás realizado cada uno de los ejercicios propuestos en este enunciado.
- El archivo .html generado al ejecutar el archivo .Rmd mediante **knit**

Consideraciones importantes

- Si el trabajo NO se entrega siguiendo las instrucciones planteadas en este enunciado quedará suspenso automáticamente.
- 1 PUNTO de la valoración final del trabajo corresponderá a:
 - La presentación, limpieza y legibilidad del documento
 - Las explicaciones generadas
 - La forma en la que se han empleado las herramientas y conceptos aprendidos durante el curso.

Además, esta puntuación solo se podrá tener en cuenta si:

- Se han realizado todos los apartados propuestos.
- La forma de envío y realización coincide con la solicitada en este enunciado.

En caso contrario, la valoración de la presentación siempre será 0



EJERCICIO 1 – ANÁLISIS EXPLORATORIO

En primer lugar, será necesario que crees un archivo .Rmd dónde:

- Importarás las librerías necesarias para el desarrollo del trabajo.
- Cargarás los datos del archivo .csv en un dataframe al que llamarás: **churn_data**

Apartado 1 – Análisis y preparación de los datos

Para este primer apartado será necesario que:

- Omitas los valores nulos del conjunto de datos.
- Utilices la función `summary()` para visualizar un resumen del conjunto de datos.
- Haciendo uso de las opciones de formato del archivo .Rmd deberás:
 - Indicar cuántas variables has visualizado en el conjunto de datos y cuáles son, especificando el tipo de dato asociado a cada una de ellas.
 - Clasificar las variables como cualitativas o cuantitativas. Es necesario que revises todas las variables detenidamente, ya que algunas variables numéricas podrían considerarse cualitativas.

En caso de que localices una variable cualitativa que inicialmente sea de tipo numérico deberás reemplazar sus valores haciendo uso de la función **`replace()`** o de una opción equivalente.
 - Factorizar todas las variables categóricas, entre las que se encuentran todas las variables cualitativas.
 - Crearás un nuevo dataframe llamado **`"clean_data"`** sin la columna llamada: `"customerID"`

Apartado 2 – Diagramas e histogramas


Haciendo uso del dataframe llamado `"clean_data"` deberás realizar un diagrama de frecuencia para cada una de las variables cualitativas del conjunto de datos y un histograma para cada una de las variables cuantitativas.



Apartado 3 – Diagramas e histogramas en función del Churn

En este apartado realizarás el mismo ejercicio que en el apartado anterior, pero coloreando los gráficos anteriores según la variable “Churn”.


A continuación, se mostrará un ejemplo de cómo deberían mostrarse los diagramas de frecuencia y los histogramas:



Apartado 4 – Boxplots

Para cada una de las variables cualitativas deberás realizar un boxplot que muestre la distribución en función del gasto mensual (“MonthlyCharges”).

Ejemplo:






Apartado 5 – Gráfico de dispersión

Para cada una de las variables cuantitativas deberás realizar un gráfico de dispersión que muestre la correlación que hay entre sí. Puedes hacerlo uno a uno o utilizando un gráfico de correlación conjunto.

Ejemplo:





EJERCICIO 2 – MODELO DE REGRESIÓN

En primer lugar, será necesario dividir el conjunto de datos **clean_data** en dos subconjuntos, uno de entrenamiento que se llamará **churn_train1** y otro de pruebas que se llamará **churn_test1**, de la siguiente forma:

- El dataframe **churn_train1** contendrá las 5000 primeras filas del conjunto de datos llamado **clean_data**
- El dataframe **churn_test1** contendrá las filas restantes del dataframe **clean_data**, es decir, a partir del registro/fila 5001 hasta el registro/fila final (ambos inclusive).

Apartado 1 – Diseño del modelo de regresión

Diseña un modelo de regresión multilíneal llamado: **lmodel**, sobre el conjunto de entrenamiento **churn_train1**, teniendo en cuenta la siguiente información:

- Deberás utilizar los datos del conjunto llamado **clean_data**
- Deberás utilizar como variable objetivo "**MonthlyCharges**".
- Deberás utilizar como variables predictoras todas menos "**TotalCharges**" y "**Churn**".

Tras ello muestra los detalles del modelo con la función **summary()** y responde las siguientes preguntas:

- ¿Cuáles son las variables/coeficientes que a un nivel de significancia del 95% podemos concluir que son "**no nulos**"?
- A partir del valor de los coeficientes, ¿cuál sería la estimación de los diferentes servicios: teléfono, DSL, Fibra, seguridad, TV, ¿... ?

Por último, deberás realizar una predicción sobre el conjunto: **churn_test1** y calcular el error promedio de las predicciones, utilizando como métrica el **RMSE** (root mean square error)



EJERCICIO 3 – MODELO DE CLASIFICACIÓN

Para la realización de este ejercicio crearás un nuevo conjunto de datos llamado: ***clean_data2***. Este deberá contener toda la información de ***clean_data*** eliminando la columna “***TotalCharges***”.

Haciendo uso del conjunto de datos ***clean_data2*** deberás diseñar varios modelos de clasificación que permitan predecir la cantidad de clientes que pueden abandonar la compañía. Para ello será necesario dividir el conjunto de datos ***clean_data2*** en dos subconjuntos, uno de entrenamiento que se llamará ***churn_train2*** y otro de pruebas que se llamará ***churn_test2***, de la siguiente forma:

- El dataframe ***churn_train2*** contendrá las 5000 primeras filas del conjunto de datos llamado ***clean_data2***
- El dataframe ***churn_test2*** contendrá las filas restantes del dataframe ***clean_data2***, es decir, a partir del registro/fila 5001 hasta el registro/fila final (ambos inclusive).

Apartado 1 – Modelo de clasificación 1

Diseña un modelo de clasificación llamado: ***gmodel1***, sobre el conjunto de entrenamiento ***churn_train2***, teniendo en cuenta la siguiente información:

- Deberás utilizar los datos del conjunto llamado ***clean_data2***
- Deberás utilizar como variable objetivo “***Churn***”.
- Deberás utilizar todas las variables como predictoras.

Después, deberás realizar la predicción del modelo sobre los datos del conjunto de testeo ***churn_test2***, para obtener la probabilidad de abandono de los clientes. A partir de dicha probabilidad tendrás que asignar a una variable llamada: ***churn_pred*** el valor “Yes” si la predicción es mayor de 0.5 y el valor “No” en caso contrario.

Tras ello será necesario que calcules la matriz de confusión en función de la siguiente tabla, también conocida como matriz de confusión:

		REAL	
		NO	YES
PREDICCIÓN	NO	TN	FN
	YES	FP	TP



A partir de la matriz de confusión, deberás calcular y mostrar:

- La **precisión global** de la predicción (**accuracy**), que se calcula mediante el uso de la siguiente fórmula:

$$\text{Precisión} = (TP + TN) / (TP + TN + FP + FN)$$

- El **ratio de falsos positivos (FPR)** que se calcula mediante el uso de la siguiente fórmula:

$$FPR = FP / (FP + TN)$$

- El **ratio de falsos negativos (FNR)** que se calcula mediante el uso de la siguiente fórmula:

$$FNR = FN / (FN + TP)$$

- El **ratio de verdaderos positivos (TPR)** que se calcula mediante el uso de la siguiente fórmula:

$$TPR = TP / (TP + FN)$$

Apartado 2 – Modelo de clasificación 2

En este apartado deberás diseñar un modelo de clasificación llamado: **gmodel2**, teniendo en cuenta la siguiente información:

- Deberás utilizar los datos del conjunto llamado **clean_data2**
- Deberás utilizar como variable objetivo **“Churn”**.
- Deberás utilizar como variables predictoras únicamente: **“Contract”**, **“Tenure”** e **“InternetService”**.

Para la realización de este apartado deberás seguir todos los pasos que seguiste para la realización del **“Modelo de clasificación 1”**, en caso contrario esta sección no se dará como válida.



EJERCICIO 4 – SIMULACIÓN DE CAMPAÑA

En este ejercicio será necesario evaluar el rendimiento económico de una campaña de retención de clientes y para ello, será necesario que diseñes un modelo de clasificación llamado: **gmodel3**, sobre el conjunto de entrenamiento **churn_train2**, teniendo en cuenta la siguiente información:

- Deberás utilizar los datos del conjunto llamado **clean_data2**
- Deberás utilizar como variable objetivo "**Churn**".
- Deberás utilizar todas las variables como predictoras.

Una vez diseñado, será necesario realizar la predicción del modelo sobre los datos del conjunto de testeo: **churn_test2**, para obtener la probabilidad de abandono de los clientes. A partir de dicha probabilidad tendrás que asignar a una variable llamada: **churn_pred** el valor "Yes" si la predicción es mayor de 0.5 y el valor "No" en caso contrario.

Tras ello será necesario que calcules la matriz de confusión en función de la tabla planteada en el ejercicio anterior.

Con esta información, podrás calcular el rendimiento de la campaña teniendo en cuenta la siguiente información:

- A los clientes clasificados por el modelo como "Churners" se les ofrecerá un teléfono de regalo a cambio de que firmen un contrato de permanencia de un año. El coste del teléfono se denominará CT.
- Los clientes aceptarán el trato con una probabilidad AR
- El beneficio asociado a la retención de un cliente lo estimamos como el consumo medio anual de un cliente menos el coste de gestión (uso de infraestructura, facturación, atención al cliente, ...).

El retorno medio estimado por cliente retenido se fijará en 500€ y se denominará R.

- Se estima que la pérdida de un cliente que abandona la compañía es igual al retorno R que genera la retención, es decir 500€.



El rendimiento se deberá calcular en diferentes umbrales de clasificación:

up = (0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9 y 1)

y en función de la probabilidad de Churn estimada por el modelo, se clasificará a los clientes en: **pred_churn = "Yes"** si la probabilidad $> up$ o **pred_churn = "No"** en caso contrario.

Conforme aumente el umbral de probabilidad, se seleccionarán menos clientes para la campaña. Por un lado, esto generará menos coste debido al incentivo que se ofrece, pero por otro lado se obtendrán menos retenciones.

El objetivo del ejercicio será encontrar el umbral óptimo en el que se obtiene un mayor rendimiento para la campaña.

Para cada umbral de probabilidad, se deberá calcular a partir de la probabilidad del modelo la variable **churn_pred** y obtener la matriz de confusión, de forma que sea posible estimar el beneficio de la campaña, sabiendo que:

Beneficio = Resultado con campaña – Resultado sin campaña

Resultado con campaña = $-FP * AR * I - TP * AR * I - TP * (1 - AR) * R - FN * R$

Donde:

- El primer y segundo término hace referencia al gasto de los teléfonos que regala la compañía a los clientes que aceptan la promoción y que no hubiesen abandonado la compañía, aunque no se hubiese realizado la campaña.
- El tercer término representa la pérdida de los clientes a los que se les ha hecho la promoción, no la han aceptado y se han marchado.
- El cuarto representa a los clientes a los que no se les ha realizado la promoción y han acabado marcándose.

Resultado sin campaña: $-(FN + TP) * R$

Donde este valor representa la pérdida de ingresos debido al abandono real de los clientes, en caso de no haber realizado la campaña. Notad que ese término no depende del modelo ajustado ni de los umbrales de probabilidad.

Es importante tener en cuenta que el resultado en ambos casos es un número negativo, ya que solo se están teniendo en cuenta las pérdidas económicas, ya sea por gasto de promoción o por la facturación esperada a futuro de un cliente que abandona la compañía.

Usando esta información, calcula los resultados de la campaña en dos escenarios de incentivos distintos.



ESCENARIO 1

Para el primer supuesto vamos a contar con la siguiente información:

- Coste del teléfono = 200€ (I)
- Probabilidad de aceptación = 0.4 (AR)
- $R = 500€$

Con ella, deberás calcular para cada umbral de probabilidad el beneficio de la campaña utilizando las fórmulas indicadas anteriormente, para finalmente responder:

- ¿Cuál sería el umbral de probabilidad para la selección de clientes óptimo para la campaña?
- ¿Qué beneficios generaría?

ESCENARIO 2

Para el segundo supuesto vamos a contar con la siguiente información:

- Coste del teléfono = 400€ (I)
- Probabilidad de aceptación = 0.8 (AR)
- $R = 500€$

Con ella, deberás calcular para cada umbral de probabilidad el beneficio de la campaña utilizando las fórmulas indicadas anteriormente, para finalmente responder:

- ¿Cuál sería el umbral de probabilidad para la selección de clientes óptimo para la campaña?
- ¿Qué beneficios generaría?

COMPARATIVA

Finalmente, deberás explicar en qué campaña (Escenario 1 o Escenario 2) se obtienen mejores beneficios, intentando argumentar el por qué.